

Testes Brown-Forsyth e Tukey no SAS

Os dois testes entram no mesmo PROC GLM que você provavelmente já usa para a ANOVA por dimensão. Basta acrescentar uma instrução MEANS com as opções certas.

Código

Supondo um conjunto de dados com os escores de cada texto nas quatro dimensões (dim1 a dim4) e a variável de grupo prompt (humano, LLM guiado, LLM livre). Ajuste os nomes aos do seu projeto:

```
ods graphics on;

proc glm data=work.escores plots=(boxplot);
  class prompt;
  model dim1 dim2 dim3 dim4 = prompt;
  means prompt / hovtest=bf welch tukey cldiff;
run;
quit;
```

Se quiser salvar as tabelas de resultado em conjuntos de dados, para montar as tabelas da dissertação, coloque antes do PROC GLM:

```
ods output HOVFTest = bf_resultados
           Welch    = welch_resultados
           CLDiffS  = tukey_resultados;
```

O que cada opção faz

Opção	Teste	Pergunta que responde	Hipótese nula
hovtest=bf	Brown-Forsythe (homogeneidade de variâncias)	Os três grupos têm a mesma dispersão de escores na dimensão?	Variâncias iguais entre os grupos
welch	ANOVA de Welch	As médias diferem, sem pressupor variâncias iguais?	Médias iguais (versão robusta)
tukey	Tukey HSD	Quais pares de grupos diferem nas médias?	Nenhuma diferença entre o par
cldiff	(formato do Tukey)	Exibe as diferenças com intervalos de confiança de 95%, em vez de apenas agrupar por letras	—

O Brown-Forsythe, no SAS, é a variante do teste de Levene que usa desvios absolutos em relação à mediana de cada grupo, e não à média, o que o torna mais robusto a distribuições assimétricas. Nas palavras dos autores, trata-se de um teste de igualdade de variâncias "robusto" a desvios da normalidade (Brown; Forsythe, 1974)

Vale um cuidado terminológico ao redigir: Brown e Forsythe publicaram em 1974 dois testes diferentes. Um testa variâncias, e é esse que o hovtest=bf executa. O outro é um F robusto para médias, disponível no SPSS, mas não nativamente no PROC GLM. O equivalente no SAS para médias é o Welch (Welch, 1951).

Por que o Brown-Forsythe interessa especialmente à sua pesquisa

O objetivo específico 3 compara a dispersão dos escores fatoriais entre humano e IA. Isso é uma pergunta sobre variância, não sobre média. O Brown-Forsythe é, portanto, o teste que responde diretamente a esse objetivo, e não apenas uma verificação de pressupostos. Se as

teorias de Tarde e Bourdieu estiverem certas, espera-se variância significativamente menor nos subcorpora de IA.

Isso também vale para a Dimensão 4. A ANOVA não foi significativa ($p = 0,0647$), mas os grupos podem ter médias iguais e dispersões diferentes. Não descarte a D4 antes de rodar o BF nela.

Como ler a sequência de resultados

Situação	Interpretação	Encaminhamento
BF não significativo	Variâncias homogêneas; pressuposto da ANOVA atendido	Reportar ANOVA clássica + Tukey normalmente
BF significativo	Dispersões diferem entre grupos (resultado substantivo para o objetivo 3)	Reportar Welch no lugar do F clássico; comparar os desvios-padrão por grupo
Tukey com IC que não inclui zero	Diferença significativa entre aquele par	Indicar direção (qual grupo tem média maior na dimensão)

Com três grupos de 1.013 textos cada, o BF tende a dar significativo mesmo para diferenças pequenas. Por isso convém reportar também os desvios-padrão por grupo, que a própria instrução MEANS já imprime, e a razão entre eles, para mostrar a magnitude da diferença e não só o p-valor.

Há ainda uma limitação do Tukey: ele pressupõe variâncias iguais. Como os grupos têm tamanhos idênticos, ele é razoavelmente robusto a essa violação. Se o seu orientador preferir uma alternativa mais rigorosa, o SAS não oferece o Games-Howell no PROC GLM.

O caminho seria o PROC GLIMMIX com variâncias residuais separadas por grupo: **(é preciso repetir para cada dimensão)**

```
proc glimmix data=work.escores;
  class prompt;
  model dim1 = prompt / ddfm=satterthwaite;
  random _residual_ / group=prompt;
  lsmeans prompt / pdiff adjust=tukey cl;
run;
```

Como inserir os códigos

Primeiro, troque os nomes pelos do seu projeto. Usei `work.escores`, `dim1-dim4` e `prompt` como exemplo. Você precisa do nome real do conjunto de dados que tem os escores de cada texto nas dimensões e dos nomes exatos das variáveis. Se o pipeline da AMD (o do repositório do `cl_st1_sara` ou os scripts) já gera esse arquivo, é só apontar para ele. Se as dimensões tiverem outro nome, como `fac1` ou `score_d1`, basta substituir na linha `model`.

Depois, confira que os escores são por texto. O teste precisa de uma linha por conto (3.039 linhas), cada uma com o grupo e os quatro escores. Se você só tiver as médias por grupo, os testes não rodam.

Também veja se `prompt` tem exatamente três categorias. Um valor escrito de forma diferente, como "humano" e "Humano", vira um quarto grupo sem avisar.

Por fim, leia o Log depois de rodar. Se aparecer algo em vermelho (ERROR) ou verde (WARNING) sobre variável não encontrada, é quase sempre nome errado.

Feito isso, sim, é só rodar. O bloco com PROC GLIMMIX é opcional e só vale a pena se o Tony pedir uma alternativa ao Tukey.

Referências

BROWN, M. B.; FORSYTHE, A. B. Robust tests for the equality of variances. *Journal of the American Statistical Association*, v. 69, n. 346, p. 364-367, 1974.

TUKEY, J. W. The problem of multiple comparisons. Princeton: Princeton University, 1953. Manuscrito não publicado.

WELCH, B. L. On the comparison of several mean values: an alternative approach. *Biometrika*, v. 38, n. 3/4, p. 330-336, 1951.